

Taller de analítica en los negocios

Analítica en ventas



Escuela de Administración y Gestión Empresarial

Directora: Lorena Baus Piva

Elaboración

Experto disciplinar: Tomás von Bischoffshausen Gariazzo

Diseñador instruccional: Óscar González Cantin

Editor instruccional: David Villagrán Ruz

Validación

Experto disciplinar: Andrés Montecinos Rùth

Jefa de diseño instruccional: Sandra Betancur Cordero

Equipo de desarrollo

AIEP

AÑO

2025

Tabla de contenidos

Aprendizaje esperado de la semana.....	4
Introducción	5
1. Ideas y conceptos relevantes	6
1.1. La estrategia de precios como marco disciplinado.....	6
1.2. Fijación de precios para un segmento y no producto.....	6
1.3. Definir el segmento objetivo y los objetivos comerciales	7
1.4. Mapa de valor.....	7
1.5. Banda de precios	7
1.6. Masa de margen de contribución.....	8
1.7. El factor estructura de costos en la fijación de precios	9
1.8. El factor demanda en la fijación de precios.....	10
1.9. Estrategias de precios basadas en el valor.....	11
1.10. El factor competencia en la fijación de precios	11
2. Función de demanda lineal	13
3. Modelo elasticidad precio-demanda.....	28
Cierre	33
Referencias	34

Aprendizaje esperado de la semana

Aplican modelo de análisis precio-demanda, a través de herramientas Python, considerando elementos de análisis para la implementación de estrategias de ventas.



Fuente: Envato Elements (s. f.)

Introducción

¿Alguna vez te has preguntado cómo las empresas determinan el precio óptimo de sus productos para maximizar ganancias sin perder clientes?

La fijación de precios es uno de los elementos más críticos en la estrategia comercial de cualquier organización. No solo determina los ingresos que una empresa puede generar, sino que también comunica el posicionamiento de la marca, establece expectativas en los consumidores y define la forma en que se enfrentará a la competencia. Una estrategia de precios bien diseñada es capaz de generar valor sostenible, mientras que una mal ejecutada puede erosionar márgenes, confundir al mercado o provocar conflictos destructivos. Para que sea efectiva, esta estrategia debe considerar múltiples factores: el cliente, el producto, los costos, el entorno competitivo y, muy especialmente, la relación entre el precio y la demanda.

¡Comencemos!

1. Ideas y conceptos relevantes

1.1. La estrategia de precios como marco disciplinado

La estrategia de precios establece un marco estructurado para tomar decisiones comerciales en un plazo aproximado de un año. Su objetivo es asegurar coherencia entre el posicionamiento de la marca, los objetivos comerciales y las condiciones del entorno competitivo. No se trata simplemente de asignar un valor monetario al producto, sino de definir cómo, para quién y en qué condiciones se establecerá ese valor.

1.2. Fijación de precios para un segmento y no producto

El precio no se define para un producto de manera aislada, sino para un segmento específico de clientes con necesidades, comportamientos y valoraciones propias. Esto se debe a que el mismo producto puede ser percibido de forma muy distinta según el contexto. Por ejemplo, un software de gestión puede ser visto como inversión estratégica por una gran empresa y como un gasto excesivo por una pyme. Fijar precios sin entender al público objetivo es arriesgarse a perder valor, participación o credibilidad.

1.3. Definir el segmento objetivo y los objetivos comerciales

Una vez identificado el segmento, la estrategia debe alinearse con los objetivos del negocio: aumentar volumen, mejorar rentabilidad, fortalecer la imagen de marca o entrar a nuevas categorías. Cada objetivo requiere enfoques distintos. Además, es necesario comprender la disposición a pagar, la sensibilidad al precio y el valor percibido por ese público, para que la estrategia se adapte al mercado real y no a supuestos abstractos.

1.4. Mapa de valor

El siguiente paso es posicionar la marca dentro del mercado, lo cual se realiza a través de un mapa de valor, que cruza precio y calidad relativa. Este puede construirse desde la percepción del consumidor o mediante datos internos. El mapa muestra cómo se ubica la marca frente a sus competidores y permite evaluar si el precio que cobra es coherente con el valor que entrega.

Ayuda a definir con mayor precisión el techo y el piso de la banda de precios, e identifica espacios competitivos estratégicos.

1.5. Banda de precios

La estrategia de precios se concreta en una banda que delimita un precio mínimo (piso) y un precio máximo (techo). Una banda estrecha indica estabilidad; una más amplia permite flexibilidad. El piso debe cubrir costos y proteger el posicionamiento de la marca. El techo, en cambio, depende de

lo que los clientes estén dispuestos a pagar, lo que nos lleva a considerar con más detalle el factor demanda.

1.6. Masa de margen de contribución

Uno de los aspectos fundamentales al analizar precios es comprender cómo estos afectan la masa de margen de contribución, es decir, el monto total disponible para cubrir los costos fijos y generar utilidad. Esta masa se calcula multiplicando el margen unitario (precio de venta menos el costo variable por unidad) por la cantidad de unidades vendidas.

Por ejemplo, si una empresa vende un producto a 100, con un costo variable de 60 por unidad, su margen unitario es de 40. Si vende 1.000 unidades, la masa de margen de contribución será de 40.000.

La importancia de esta métrica radica en que permite analizar el impacto financiero directo de cada decisión de precio. Un aumento de precio mejora el margen por unidad, pero puede reducir la cantidad de unidades vendidas. Una reducción de precio puede aumentar el volumen de ventas, pero disminuir el margen unitario. El desafío es encontrar el equilibrio: ¿cuánto puedo subir el precio sin perder demasiado volumen?, ¿cuánto debo vender para compensar una baja en el precio?

Este análisis permite anticipar escenarios y tomar decisiones informadas. Además, al incorporar fórmulas específicas, se pueden estimar, por ejemplo, cuántas unidades adicionales se deben vender para mantener la masa de margen constante después de una rebaja de precios, o qué caída máxima de volumen se puede tolerar ante un alza. Así, la masa de margen de contribución conecta directamente la estrategia de precios con la rentabilidad real del negocio.

1.7. El factor estructura de costos en la fijación de precios

La estructura de costos de una empresa influye directamente en su capacidad para tomar decisiones de precios. En particular, la proporción entre costos fijos y costos variables define cuánto riesgo y flexibilidad tiene una empresa al ajustar sus precios.

Empresas con una estructura de costos mayoritariamente fija —como aerolíneas, empresas tecnológicas o de manufactura intensiva— pueden reducir precios para aumentar el volumen de ventas sin que sus costos totales aumenten en la misma proporción. Esto se debe a que, una vez cubiertos los costos fijos (como arriendo, sueldos administrativos o amortización de equipos), cada venta adicional contribuye directamente a generar utilidad.

En cambio, las empresas con alta proporción de costos variables —como importadores o distribuidores— tienen menos margen de maniobra para bajar precios, porque cada unidad adicional vendida implica un costo adicional significativo. Si bajan demasiado el precio, podrían terminar vendiendo más pero ganando menos, o incluso perdiendo dinero.

Este equilibrio también está influido por decisiones estratégicas como tercerizar procesos (lo que aumenta los costos variables) o integrar operaciones internamente (lo que eleva los costos fijos). Por eso, conocer la propia estructura de costos es clave para definir una estrategia de precios sostenible.

1.8. El factor demanda en la fijación de precios

La demanda es central al definir precios, ya que determina cuánto están dispuestos a pagar los clientes y cómo reaccionarán ante cambios en el precio. Para entender este comportamiento, el análisis precio-demanda se apoya en tres conceptos clave:

- **Precio de referencia:** es la idea que tiene el cliente sobre cuánto "debería" costar un producto. Actúa como una ancla mental que influye en la percepción de caro o barato.
- **Valor percibido:** es la relación subjetiva entre los beneficios que el cliente cree que recibirá y los costos que asume. Cuanto mayor sea este valor, mayor será su disposición a pagar.
- **Valor económico en uso:** es la estimación interna que hace la empresa sobre cuánto valor monetario genera su producto en comparación con la mejor alternativa.

Estos tres factores no reemplazan el análisis precio-demanda, sino que lo complementan. Ayudan a explicar por qué un mismo cambio de precio puede tener efectos distintos según el cliente o el contexto. Integrarlos en el análisis permite interpretar mejor la elasticidad de la demanda y tomar decisiones más precisas sobre precios, promociones y segmentación.

Por eso, es importante segmentar adecuadamente a los clientes antes de aplicar el análisis precio-demanda. Cada segmento puede tener distintos precios de referencia, niveles de valor percibido y valor económico real, lo que significa que su comportamiento ante variaciones de precio también será distinto. Esta segmentación previa permite modelar con mayor

precisión las reacciones de cada tipo de cliente ante distintos escenarios de precios.

1.9. Estrategias de precios basadas en el valor

A partir del análisis del valor percibido y del comportamiento de la demanda, se pueden aplicar estrategias como:

- **Descreme:** fijar precios altos cerca del valor percibido, capturando gran parte del valor en segmentos premium, con baja sensibilidad al precio.
- **Penetración:** fijar precios bajos en relación con el valor percibido, generando un alto excedente para el cliente y estimulando el volumen.

La clave está en que el precio no sea evaluado como 'caro' o 'barato' en términos absolutos, sino en relación con el valor que el cliente percibe.

1.10. El factor competencia en la fijación de precios

La mayoría de las empresas enfrenta competencia directa o indirecta. Los precios deben considerar no solo al cliente, sino también las posibles reacciones del entorno competitivo. Incluso si el análisis del valor percibido sugiere que se puede cobrar más, la competencia puede imponer límites prácticos si ofrece opciones similares a menor precio o si tiene una estructura de costos más eficiente.

Por eso, el análisis precio-demanda también debe considerar el precio relativo frente a las alternativas disponibles, y anticipar si una acción provocará una reacción competitiva.

Ideas finales

La fijación de precios es una decisión estratégica que integra múltiples dimensiones del negocio. Una estrategia bien diseñada parte del entendimiento profundo del cliente, del análisis del valor entregado, del posicionamiento deseado, de los costos y del contexto competitivo. Incorporar el análisis precio-demanda y complementarlo con el precio de referencia, el valor percibido y el valor económico en uso permite anticipar resultados, evitar conflictos y construir ventajas sostenibles. Cuando se aplica con claridad y método, la estrategia de precios deja de ser una herramienta táctica y se transforma en un pilar del crecimiento y la diferenciación empresarial.

2. Función de demanda lineal

La función de demanda lineal $Demanda = a - b \cdot Precio$ se obtiene a partir de modelos econométricos que buscan explicar la relación entre la cantidad demandada y el precio de un bien. Wooldridge (2020) aborda la estimación de este tipo de relaciones mediante regresión lineal, utilizando datos observados para cuantificar la sensibilidad de la demanda ante cambios en el precio.

Modelo econométrico de demanda

En econometría, se parte de una ecuación de regresión simple:

$$Q = \beta_0 + \beta_1 P + u$$

Donde:

- (Q) es la cantidad demandada.
- (P) es el precio del bien.
- (β_0) representa la demanda teórica cuando el precio es cero.
- (β_1) mide la variación de la demanda ante cambios en el precio (sensibilidad o elasticidad precio).
- (u) es el término de error, que captura factores no observados que afectan la demanda.

Estimación de los parámetros

Para obtener la versión empírica de la ecuación, se utilizan datos históricos o simulados sobre ventas y precios, aplicando el método de mínimos

cuadrados ordinarios (MCO). Este método minimiza la suma de los errores cuadráticos y estima (β_0) y (β_1) como:

$$\hat{\beta}_1 = \frac{\sum (P_i - \bar{P})(Q_i - \bar{Q})}{\sum (P_i - \bar{P})^2}$$
$$\hat{\beta}_0 = \bar{Q} - \hat{\beta}_1 \bar{P}$$

Estos coeficientes permiten determinar la ecuación específica de la demanda para la empresa analizada.

Interpretación de la ecuación obtenida

Si los datos proporcionados indican que:

- ($a = 1000$) (es decir, cuando ($P = 0$), la demanda teórica es 1000 unidades).
- ($b = 5$) (lo que significa que por cada aumento de una unidad en el precio, la demanda disminuye en 5 unidades).

La ecuación final es:

$$Demanda = 1000 - 5 \cdot Precio$$

Este modelo es útil para predecir la cantidad demandada a diferentes niveles de precio y para calcular la elasticidad precio de la demanda.

Imaginemos que una empresa que comercializa dispositivos inteligentes está evaluando cuál es la sensibilidad de la demanda ante diferentes precios. Para ello, se parte de una función de demanda lineal estimada a partir de datos simulados:

$$Demanda = a - b \cdot Precio$$

Donde:

- $a = 1000$: demanda máxima teórica si el precio fuera cero.
- $b = 5$: sensibilidad de la demanda al precio.
- Precio: valor unitario de venta.

Veamos un ejemplo aplicado de lo anterior:

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt

# Fijar semilla para reproducibilidad
np.random.seed(42)

# Número de observaciones
n = 100

# Generar precios aleatorios entre 10 y 200
precios = np.linspace(10, 200, n)

# Generar demanda a partir de la ecuación de demanda con algo de ruido
a = 1000 # Demanda máxima teórica
b = 5 # Sensibilidad de la demanda al precio
error = np.random.normal(0, 50, n) # Ruido con distribución normal
demandas = a - b * precios + error # Demanda real con ruido

# Crear el DataFrame con los datos generados
df = pd.DataFrame({'Precio': precios, 'Demanda': demandas}) df.head()

{"summary":{"name": "df", "rows": 100, "fields": [{"column": "Precio", "properties": {"dtype": "number", "std": 55.67862096381398, "min": 10.0, "max": 200.0, "num_unique_values": 100, "samples": [{"169.29292929292927, 111.71717171717171, 171, 171}]}]}
```



```
144.34343434343432\n                ],\n                \"semantic_type\": \"\",\n                \"description\": \"\"\n            },\n            {\n                \"column\": \"Demanda\",\n                \"properties\": {\n                    \"dtype\": \"number\",\n                    \"std\": 280.07028726858346,\n                    \"min\": -34.79190902276747,\n                    \"max\": 997.3636140325225,\n                    \"num_unique_values\": 100,\n                    \"samples\": [\n                        127.6218426216712,\n                        471.997955856184,\n                        83,\n                        296.35260855824913\n                    ],\n                    \"semantic_type\": \"\",\n                    \"description\": \"\"\n                }\n            }\n        ],\n        \"type\": \"dataframe\", \"variable_name\": \"df\"}
```

La validación de los supuestos en un modelo de regresión lineal es fundamental para garantizar que los resultados obtenidos sean fiables. Los supuestos clave de la regresión lineal, particularmente en el contexto de Mínimos Cuadrados Ordinarios (MCO), son:

1. **Linealidad:** la relación entre las variables dependientes e independientes es lineal. Esto se verifica observando la gráfica de dispersión de los datos y asegurando que la línea de regresión se ajuste razonablemente bien a los datos.
2. **Independencia:** las observaciones son independientes entre sí. Este supuesto puede validarse mediante pruebas como el Durbin-Watson para detectar autocorrelación en los residuos.
3. **Homoscedasticidad:** la varianza de los residuos es constante en todos los niveles de la variable independiente. Si la varianza cambia (heteroscedasticidad), los resultados pueden ser ineficientes. Se puede comprobar mediante un gráfico de residuos vs. valores ajustados o utilizando pruebas estadísticas como la prueba de Breusch-Pagan.

4. **Normalidad de los residuos:** los residuos deben seguir una distribución normal. Esto se puede verificar mediante un gráfico de probabilidades (Q-Q plot) o una prueba estadística como el Shapiro-Wilk o el Jarque-Bera.
5. **No multicolinealidad:** en modelos con más de una variable independiente, las variables no deben estar altamente correlacionadas entre sí. En este caso, dado que solo tienes una variable independiente (precio), este supuesto no es relevante.

Veamos si se cumplen los supuestos:

```
import statsmodels.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
import scipy.stats as stats

# Ajuste del modelo de regresión (como ya tienes en tu código)
X = sm.add_constant(df['Precio'])
modelo = sm.OLS(df['Demanda'],
X).fit()

# Predicciones del modelo y
residuos residuos =
modelo.resid predicciones =
modelo.fittedvalues

# 1. Comprobación de Linealidad (Graficar datos y línea de regresión
ajustada)
plt.figure(figsize=(10, 6))
plt.scatter(df['Precio'], df['Demanda'], label='Datos observados',
color='blue', alpha=0.6)
plt.plot(df['Precio'], beta_0_estimado + beta_1_estimado *
df['Precio'], label='Línea de demanda estimada', color='red',
linewidth=2)
plt.title('Relación entre Precio y Demanda con Ajuste de
Regresión Lineal')
plt.xlabel('Precio
')
plt.ylabel('Demand
a') plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```

# 2. Comprobación de Homoscedasticidad (Gráfico de residuos vs.
valores ajustados)
plt.figure(figsize=(10, 6))

plt.scatter(predicciones, residuos, color='green',
alpha=0.6) plt.axhline(y=0, color='red', linestyle='--')
plt.title('Gráfico de Residuos vs. Valores Ajustados')
plt.xlabel('Valores ajustados')
plt.ylabel('Residuos')
plt.grid(True)
plt.tight_layout()
plt.show()

# 3. Comprobación de Normalidad de los residuos (Histograma y
prueba de normalidad)
plt.figure(figsize=(10, 6))
sns.histplot(residuos, kde=True, color='purple',
bins=20) plt.title('Distribución de los Residuos')
plt.xlabel('Residuos')
plt.ylabel('Frecuencia') plt.tight_layout()
plt.show()

# Prueba de normalidad de los residuos (Shapiro-Wilk)
_, p_value_normalidad = stats.shapiro(residuos)
print(f"P-valor de la prueba de normalidad de los residuos:
{p_value_normalidad:.4f}")

# 4. Comprobación de Independencia de los residuos (Prueba de
Durbin- Watson)
durbin_watson = sm.stats.durbin_watson(residuos)
print(f"Estadístico de Durbin-Watson:
{durbin_watson:.2f}")

# Mostrar resumen del modelo
print("\nResumen del modelo de
regresión:") print(modelo.summary())

```




Figura 1. Relación entre precio y demanda con ajuste de regresión lineal




Figura 2. Grafico de residuos vs. valores ajustados




Figura 3. Distribución de los residuos

P-valor de la prueba de normalidad de los residuos: 0.7928
 Estadístico de Durbin-Watson: 2.04

Resumen del modelo de regresión:

OLS Regression Results

```

=====
=====
Dep. Variable:          Demanda    R-squared:
0.974
Model:                  OLS        Adj. R-squared:
0.973
Method:                 Least Squares    F-statistic:
3637.
Date:                   Tue, 25 Mar 2025    Prob (F-statistic):
2.73e-79
Time:                   23:10:54    Log-Likelihood:
-522.86
No. Observations:      100    AIC:
1050.
Df Residuals:          98    BIC:
1055.
Df Model:               1
Covariance Type:       nonrobust
=====
=====

```

	coef	std err	t	P> t	[0.025
					0.975]

const	990.9964	9.771	101.426	0.000	971.607
1010.386					
Precio	-4.9637	0.082	-60.312	0.000	-5.127
-4.800					
=====					
Omnibus:		0.521	Durbin-Watson:		
2.042					
Prob(Omnibus):		0.771	Jarque-Bera (JB):		
0.518					
Skew:		-0.167	Prob(JB):		
0.772					
Kurtosis:		2.885	Cond. No.		
254.					
=====					
Notes:					
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.					

Figura 4. Resumen del modelo de regresión

Interpretación

- Linealidad:
 - El gráfico de dispersión muestra la relación entre el precio y la demanda, con la línea de regresión ajustada. Si los puntos siguen la tendencia de la línea, el supuesto de linealidad se cumple.
- Homoscedasticidad:
 - El gráfico de residuos contra los valores ajustados (predicciones) permite verificar si la varianza de los residuos es constante. Si los residuos están distribuidos aleatoriamente sin patrones claros (sin abanico o embudo), el supuesto de homoscedasticidad se cumple.

- Normalidad de los residuos:
 - Un histograma de los residuos muestra su distribución. Si la distribución es aproximadamente normal, esto valida el supuesto de normalidad. Además, se realiza una prueba de normalidad de Shapiro-Wilk para obtener un valor p. Si el p-valor es mayor que 0.05, podemos suponer que los residuos siguen una distribución normal.
- Independencia:
 - La prueba de Durbin-Watson mide la autocorrelación de los residuos. Un valor cercano a 2 indica que no hay autocorrelación significativa. Valores cerca de 0 indican autocorrelación positiva, y valores cerca de 4 indican autocorrelación negativa.

Nuestros datos cumplen con los supuestos antes expuestos, por lo que podemos aplicar regresión lineal (mínimos cuadrados ordinarios - MCO) para estimar la función de demanda.

```
# Aplicar regresión lineal (mínimos cuadrados ordinarios - MCO) para
estimar la función de demanda

X = sm.add_constant(df['Precio']) # Agregar constante para el
intercepto ( $\beta_0$ )

modelo = sm.OLS(df['Demanda'], X).fit() # Ajustar modelo de
regresión beta_0_estimado, beta_1_estimado = modelo.params #
Extraer coeficientes

# Mostrar los resultados de la estimación
print(f"Coeficiente estimado para la demanda máxima (a):
{beta_0_estimado:.2f}")
print(f"Coeficiente estimado para la sensibilidad al precio (b):
{beta_1_estimado:.2f}")

# Crear el gráfico de la demanda observada y la línea de regresión
ajustada

plt.figure(figsize=(10,6))
```

```

# Graficar los datos observados (precio vs demanda)
plt.scatter(df['Precio'], df['Demanda'], label='Datos observados',
color='blue', alpha=0.6)

# Graficar la línea de regresión estimada
plt.plot(df['Precio'], beta_0_estimado + beta_1_estimado
* df['Precio'], label='Línea de demanda estimada',
color='red', linewidth=2)

# Etiquetas y título
plt.title('Relación entre Precio y Demanda con Ajuste de Regresión
Lineal')

plt.xlabel('Precio'
)
plt.ylabel('Demanda
') plt.legend()
plt.grid(True)

# Mostrar el
gráfico
plt.tight_layout
() plt.show()

# Mostrar el resumen completo del modelo
print("\nResumen del modelo de regresión:")
print(modelo.summary())

```

Coeficiente estimado para la demanda máxima (a): 991.00
Coeficiente estimado para la sensibilidad al precio (b): -
4.96




Figura 5. Relación entre precio y demanda con ajuste de regresión lineal

Resumen del modelo de regresión:

OLS Regression Results

```
=====
=====
Dep. Variable:          Demanda    R-squared:
0.974
Model:                  OLS        Adj. R-squared:
0.973
Method:                 Least Squares    F-statistic:
3637.
Date:                   Tue, 25 Mar 2025    Prob (F-statistic):
2.73e-79
Time:                   23:10:54    Log-Likelihood:
-522.86
No. Observations:       100    AIC:
1050.
Df Residuals:           98    BIC:
1055.
Df Model:                1
Covariance Type:        nonrobust
```

```
=====
=====
coef    std err          t      P>|t|      [0.025
```

```

0.975]
-----
-----
const          990.9964      9.771      101.426      0.000      971.607
1010.386
Precio         -4.9637      0.082      -60.312      0.000      -5.127
-4.800
=====
=====
Omnibus:                0.521      Durbin-Watson:
2.042
Prob(Omnibus):          0.771      Jarque-Bera (JB):
0.518
Skew:                   -0.167      Prob(JB):
0.772
Kurtosis:               2.885      Cond. No.
254.
=====
=====

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is
correctly specified.

```

Figura 6. Resumen del modelo de regresión

Ahora, interpretemos los resultados:

- R-squared (R^2)
 - Valor: 0.974
 - Significado: este valor indica que el 97.4% de la variabilidad de la demanda está explicada por el precio en el modelo. Esto sugiere un ajuste muy bueno entre la relación precio-demanda.
- Coeficiente de precio (*Slope* o pendiente)
 - Valor: -4.9637
 - Significado: este coeficiente muestra la sensibilidad de la demanda al precio. Por cada aumento de 1 unidad en el precio, la demanda disminuye en aproximadamente 4.96 unidades. Es decir, existe una relación negativa entre precio y demanda.

- P-valor de precio
 - Valor: 0.000
 - Significado: el p-valor extremadamente bajo (menor a 0.05) indica que el coeficiente del precio es estadísticamente significativo. Es decir, el precio tiene un impacto real en la demanda y no es producto del azar.
- Intercepto (constante)
 - Valor: 990.9964
 - Significado: este es el valor estimado de la demanda cuando el precio es cero. En otras palabras, si el precio fuera cero, la demanda teórica sería de 991 unidades.
- P-valor del intercepto
 - Valor: 0.000
 - Significado: el p-valor asociado al intercepto también es extremadamente bajo, lo que indica que el intercepto es estadísticamente significativo y no es producto del azar.
- F-statistic y Probabilidad de F-statistic
 - Valor F-statistic: 3637
 - Probabilidad (p-value de F): 2.73e-79
 - Significado: el valor F alto (3637) y la probabilidad muy baja (2.73e-79) indican que el modelo en general es altamente significativo y que la relación entre precio y demanda es fuerte y no aleatoria.
- Durbin-Watson (DW)
 - Valor: 2.042
 - Significado: un valor cercano a 2 sugiere que no hay autocorrelación significativa en los residuos del modelo, lo que indica que el modelo es adecuado y los errores no están correlacionados.

- Intervalos de confianza para los coeficientes
 - Constante: [971.607, 1010.386]
 - Precio: [-5.127, -4.800]
 - Significado: los intervalos de confianza estrechos para ambos coeficientes muestran que estimamos con alta precisión los valores de intercepto y pendiente, lo que aumenta la fiabilidad de los resultados.

Conclusión: el modelo tiene un ajuste muy bueno con un R^2 de 0.974, lo que significa que el precio explica gran parte de la variabilidad de la demanda. Además, la relación negativa entre precio y demanda es estadísticamente significativa, lo que sugiere que a medida que aumenta el precio, la demanda disminuye. Este modelo puede ser útil para predecir la demanda a diferentes precios con alta precisión.

3. Modelo elasticidad precio-demanda

El modelo elasticidad precio-demanda mide cómo la cantidad demandada de un producto responde a cambios en su precio, permitiendo determinar la sensibilidad de los consumidores ante variaciones de precio.

Veamos cómo calcular esto con Python:

```
# Código en Python para calcular elasticidad y visualizar sensibilidad

import numpy as np # Biblioteca para cálculos numéricos
import pandas as pd # Biblioteca para manipulación de datos
en DataFrames

import matplotlib.pyplot as plt # Biblioteca para visualización de
datos

# Definición de parámetros base
costo_variable = 40 # Costo variable por unidad del producto
precios = np.linspace(45, 150, 100) # Rango de precios entre $45 y
$150 con 100 valores intermedios

a = 1000 # Intercepto de la demanda (cantidad demandada si el
precio fuera 0)

b = 5 # Sensibilidad de la demanda al precio (coeficiente de
pendiente)

# Cálculo de la demanda estimada para cada precio
demandas = a - b * precios # Aplicación de la función de
demanda lineal

# Cálculo del margen unitario (precio menos costo variable)
margen_unitario = precios - costo_variable

# Cálculo de la masa de margen de contribución (beneficio total)
masa_margen = demandas * margen_unitario

# Creación de un DataFrame para almacenar los resultados
df =
    pd.DataFrame
    ({ 'Precio':
    precios,

    'Demanda estimada':
```



```

{"dtype": "number",\n          "std": 8103.939747841279,\n "min": 3875.0,\n          "max": 31999.540863177226,\n "num_unique_values": 100,\n          "samples": [\n 31151.05601469238,\n          30235.0780532598\n 7,\n\n 31997.13039485767\n ],\n          "semantic_type": "\"",\n "description": "\""\n }\n },\n {\n          "column":\n "Elasticidad",\n          "properties": {\n          "dtype":\n "number",\n          "std": 0.7336632988294858,\n          "min": - 3.0,\n          "max": -0.2903225806451613,\n\n "num_unique_values": 100,\n          "samples": [\n 1.9864253393665157,\n          -1.0245398773006138,\n          -\n\n 1.4765478424015006\n ],\n          "semantic_type": "\"",\n "description": "\""\n }\n ]\n }\n },\n {"type": "dataframe", "variable_name":\n "df"}

```

Determinación del precio óptimo para maximizar la masa de margen de contribución

```

indice_optimo = np.argmax(df['Masa de margen de contribucion']) #
Índice del valor máximo
precio_optimo = precios[indice_optimo] # Precio correspondiente
al margen máximo

```

```

masa_max = masa_margen[indice_optimo] # Valor máximo de la masa
de margen

```

Impresión de resultados clave

```

print(f"Precio óptimo: ${precio_optimo:.2f}")
print(f"Masa de margen de contribución máxima: ${masa_max:,.2f}")

```

```

# Gráfico 1: Elasticidad-precio de la demanda
plt.figure(figsize=(10,5)) # Definir tamaño de la figura
plt.plot(df['Precio'], df['Elasticidad'], label='Elasticidad-
precio', color='green') # Graficar elasticidad

```

```

plt.axhline(y=-1, color='red', linestyle='--', label='Elasticidad
= - 1') # Línea de referencia en elasticidad = -1

```

```
plt.title('Elasticidad-precio de la demanda') # Título del
gráfico plt.xlabel('Precio') # Etiqueta del eje X
plt.ylabel('Elasticidad') # Etiqueta del eje Y

plt.grid(True) # Agregar cuadrícula para mejor visualización
plt.legend() # Mostrar leyenda
plt.tight_layout() # Ajustar diseño para evitar superposición
plt.show() # Mostrar gráfico
```

Precio óptimo: \$120.30

Masa de margen de contribución máxima: \$31,999.54




Figura 7. Elasticidad-precio de la demanda

```
# Identificar el precio óptimo
indice_optimo = np.argmax(masa_margen)
precio_optimo = precios[indice_optimo]
masa_max = masa_margen[indice_optimo]

# Mostrar resultado
print(f"Precio óptimo: ${precio_optimo:.2f}")
print(f"Masa de margen de contribución máxima: ${masa_max:,.2f}")

# Visualización
df.plot(x='Precio', y=['Masa de margen de contribucion'],
figsize=(10,6), grid=True)

plt.axvline(precio_optimo, color='red', linestyle='--',
label='Precio óptimo')
```



```
plt.title('Masa de margen de contribución según precio')
plt.xlabel('Precio')

plt.ylabel('Masa de margen de contribución')
plt.legend()

plt.tight_layout()
plt.show()
```

Precio óptimo: \$120.30

Masa de margen de contribución máxima: \$31,999.54





Figura 8. Masa de margen de contribución según precio

Cierre

Por medio del siguiente organizador gráfico se destacan las ideas clave de esta semana:



El análisis precio-demanda es una herramienta muy relevante para el diseño y la ejecución de una estrategia de precios eficaz. Al comprender la relación entre el precio de un producto y la cantidad demandada, las empresas pueden tomar decisiones más informadas que optimicen sus márgenes de contribución y mejoren su competitividad en el mercado. La integración de factores como el valor percibido, el precio de referencia, y la elasticidad de la demanda permite segmentar adecuadamente el mercado, ajustar los precios según las expectativas de los consumidores y anticipar posibles reacciones de la competencia. Además, la aplicación de modelos econométricos, como la función de demanda lineal, permite prever cómo los cambios en el precio afectarán las ventas, facilitando la adaptación de la estrategia para maximizar tanto la rentabilidad como el crecimiento empresarial.

Referencias

Envato Elements (s. f.). Visión desde un ángulo elevado de los trabajadores.

[Imagen]. <https://elements.envato.com/es/high-angle-view-on-working-people-VK423DJ>

(s.f.) Análisis financiero, concepto de investigación de indicadores económicos [Imagen]. <https://elements.envato.com/es/finance-analytics-research-of-economic-indicators--9DQPGG6>

Wooldridge, J. M. (2020). *Introductory Econometrics: A Modern Approach* (7ª ed.). Cengage Learning.